北 京 师 范 大 学

硕士研究生学位论文开题报告

研 究 生 姓 名 _____

学　　号 _____

导师姓名、职称 _____

培 养 单 位 心理学部

专　　业 应用心理

研 究 方 向 用户体验（UX）

入 学 时 间 20 年 月

论 文 题 目 苏格拉底式智能体辅助阅读对科研新手文献批判性评价表现的影响

一、立论依据

（选题的研究意义、国内外研究现状分析）

1．选题的研究意义

1.1 研究背景与问题提出

阅读研究论文是科研训练中的基本活动。科研新手既需要理解研究问题、方法和结果，也需要判断研究方法与证据是否足以支持作者的结论。这要求学生把方法课程中学过的原则运用到具体研究中，识别影响推断的问题，并说明判断的依据。Meltzoff 和 Cooper（2018）通过模拟研究及配套评析，将这一过程落实到研究问题、样本、设计、测量、分析和解释等环节；Sternberg 和 Sternberg（2017）则通过审稿人任务考察学生能否从研究报告中发现有效问题。文献批判性评价由此成为可以通过具体任务训练和观察的科研活动。

AI 工具使科研新手能够随时获得论文解释、总结和评价，但工具支持下的任务完成与学习者自身的能力发展需要分别考察。近期实验发现，生成式 AI 能够改善练习或作品表现，但这种优势未必延续到独立测验、知识获得或后续应用中（Bastani et al., 2025; Fan et al., 2025）。针对论文阅读，CriTrainer 已将训练效果落实到撤去工具后的自主提问表现（Yuan et al., 2023）。如何组织 AI 与学习者的互动，使阅读中的帮助转化为独立评价研究的能力，是科研阅读工具需要回答的问题。

本研究关注具备基础方法课程知识、科研实践经验有限的科研新手，拟开发苏格拉底式文献阅读 Agent，通过追问判断依据、推理联系和结论边界，引导学生解释自己的研究评价，并根据困难提供提示或讲解。研究比较无 AI 独立阅读、通用 Agent 辅助阅读与苏格拉底式 Agent 辅助阅读三种方式，考察训练后的独立缺陷识别和解释质量。

1.2 理论意义

本研究将生成性学习与自我解释落实到科研论文评价任务。对科研新手而言，记得某条方法学原则与能在具体论文中使用该原则之间，仍有需要完成的推理。例如，知道“相关不等于因果”并不能直接回答一篇研究是否已经通过设计与分析排除了主要替代解释。让学生解释原文中的设计、所采用的方法原则及结论之间的关系，有助于把这一推理过程变成可以支持和观察的学习活动。

本研究拟考察，围绕这些关系展开的连续追问能否改善后续独立评价。主要结果分别反映有效缺陷的发现与解释的充分程度，对话记录则用于描述学生何时生成理由、如何回应提示以及如何修正判断。由此，将学习理论中的加工要求、Agent 的互动策略与具体任务表现联系起来，为理解苏格拉底式支持在科研训练中的作用提供情境化证据。

1.3 实践意义

科研新手在日常阅读中遇到的问题通常是具体的：某个术语不明白、找不到支撑结论的数据，或者觉得研究有问题却无法说明理由。AI 阅读工具能够及时回应这些疑问，但回应方式会影响学生接下来是直接采纳分析，还是继续检查原文并形成自己的解释。本研究拟把澄清内容、追问理由和适度提示整合到同一阅读过程中，使学生能够围绕自己的问题接受支持。

研究成果将包括可运行的文献阅读 Agent、追问与帮助规则、可用性测试记录及论文评价评分手册。三组实验将比较不同支持方式下的独立表现，为 AI 文献阅读工具怎样组织对话、何时提供解释、怎样保留学生推理空间提供设计依据，也为心理学及相关专业的研究方法训练提供可参考的活动形式。

2．国内外研究现状分析

2.1 文献批判性评价的概念与测量

Facione（1990）的专家共识将批判性思维描述为有目的、自我调节的判断，涉及解释、分析、评价、推论、说明和自我调节等技能。其中，分析证据与主张的联系、评价推断是否成立、说明判断的理由，与研究论文阅读直接相关。科研文献批判性评价需要将这些技能与具体的方法学知识结合。例如，学生不能仅凭论文提到“实验组”就接受因果结论，而应进一步检查分组方式、比较条件以及可能的替代解释。

本研究将文献批判性评价表现界定为：学习者在理解论文的基础上，识别具体、成立的研究缺陷，并结合文中信息解释该缺陷为什么影响研究判断的表现。相应地，评价重点包括缺陷识别与解释质量。论文内容概括作为理解表现单独测量，用于观察学生是否准确把握研究问题、方法、主要结果和作者结论。

批判性思维技能与批判性思维倾向也需要分别测量。前者表现为在具体任务中能否作出有效判断；后者涉及是否愿意寻求理由、考虑证据和认真检查判断。CCTDI 用于评价批判性思维倾向（Insight Assessment, n.d.）。本研究以实际论文任务作为主要结果测量，将初始倾向用于探索学习者差异。

2.1.1 从内容理解到研究评价

论文内容理解为评价提供基础。研究者需要先确认作者提出的问题、变量如何测量、研究采用何种比较以及结果实际显示了什么，才能判断结论是否得到支持。概括得分能够呈现这类信息是否被正确理解，但完整概括一篇论文并不自动包含对证据质量的判断。相应地，批判性评价要求学习者进一步检查研究做法与推断之间的关系。

“缺陷识别”与“解释质量”也包含不同要求。学生可能发现了研究没有随机分组，却只能笼统地说“不够科学”；也可能只发现一个问题，但能明确解释原有差异如何形成替代解释。本研究将这两类表现分别计分，以观察训练是在扩展学生能够发现的问题范围，还是帮助其更充分地论证已经形成的评价。

评价对象限定为研究中的具体问题及其对推断的影响。泛泛地要求“样本应更大”“方法应更

多”并不足以说明缺陷成立；学生需要结合研究目标和实际信息解释为什么需要这样改进。研究评价还可能得出某项设计合理、某一批评不成立或现有报告不足以判断的结论。因此，训练中的对话围绕证据是否支持判断展开，测验则记录学生提出的有效缺陷与理由。

2.1.2 基于研究报告的表现性测量

Sternberg 和 Sternberg（2017）在心理学及相关学科的科学推理测量中设置审稿人任务，让参与者阅读简短的模拟研究报告，以开放文本指出研究问题，并根据有效回答计分。该任务为通过“读研究—找问题”的方式观察科学推理提供了依据。与一般性自评相比，开放式研究评价能够直接呈现学生发现了什么、依据是什么，也便于区分有效批评与笼统质疑。

Meltzoff 和 Cooper（2018）提供了 17 篇简短的模拟研究文章及配套评析，涵盖研究问题与假设、样本和分组、研究设计、变量测量、数据分析及结论解释等方面。这类材料保留了完整研究的基本结构，同时使研究中的问题可以由配套评析和专家审查共同核定，适合用于科研新手的训练与评价。本研究拟从中选择篇幅、知识要求和评价难度相近的材料，形成训练与前后测文章。

仅计算发现的问题数量，还不能充分反映学生评价的质量。Timmerman 等人（2011）开发的科学写作评分量规，将研究假设、设计、数据分析和讨论等环节转化为可观察的科学推理表现，强调评价理由与证据之间的联系。Arriagada Anabalón 等人（2026）依据批判性思维框架，对师范生学术写作中的解释、分析、说明和评价分别评分，并报告独立评分的一致性。该研究为解释质量分档提供了参考，其固定任务顺序且缺少对照组的设计，也提示学习效果需要结合合适的比较条件判断。

据此，本研究拟以“有效缺陷数占预设有效缺陷总数的比例”反映缺陷识别击中率，以有效缺陷解释的平均得分反映解释质量，并补充计算有效缺陷占全部所提不同缺陷的比例，即缺陷识别精确率。三者分别回答发现了多少有效问题、解释得怎么样，以及提出的批评中有多少成立。评分标准将结合具体论文、专家评析与试评结果制定。

2.1.3 测量依据与本研究指标的对应

上述文献为本研究提供的是相互补充的测量依据。Sternberg 和 Sternberg（2017）支持让学生以开放文本评价模拟研究；Meltzoff 和 Cooper（2018）为选择文章、梳理研究问题及核对评价依据提供材料基础；Timmerman 等人（2011）和 Arriagada Anabalón 等人（2026）为根据证据与推理质量划分表现水平提供参考；CriTrainer 则展示了把内容概括与批判性阅读产出分开评价的实验思路（Yuan et al., 2023）。

本研究将据此编制与所选文章相匹配的评分手册。手册既说明哪些问题成立，也说明何种文字足以体现学生识别了该问题，以及解释达到不同水平时有哪些可观察特征。采用四位评分者独立盲评和一致性分析，使评分依据能够在不同参与者、不同时间的回答之间保持一致。具体计分与质量控制安排在研究方案中展开。

2.2 国内相关实证研究

2.2.1 AI 使用与批判性思维的关系

国内近年的调查研究表明，AI 使用与批判性思维的关系需要结合使用方式考察。戚佳等人（2024）基于 1,781 份高校学生问卷，发现使用生成式 AI 工具的学生以及持续使用者，在批判性思维与自主学习能力指标上表现较好；同时，多数学生向 AI 提出的问题仍以封闭式问题为主。这说明“是否使用 AI”之外，还需要关注学生在互动中完成了什么思考活动。

蔡颖蔚和陈茁（2025）分析 10,964 份大学生问卷，发现 AI 使用频率与批判性思维之间呈 U 形关系，使用目的的广度及价值认同与批判性思维存在正向关系。两项研究均提示，使用 AI 不能简单等同于认知能力的提高或降低。问卷能够揭示学生使用行为与自报能力的关联，而要判断具体支持方式的学习效果，还需要控制条件的实验与实际任务测量。

2.2.2 苏格拉底式支持与人机互动设计

李海峰等人（2024）在两个教育技术学本科班开展准实验，比较使用“智能苏格拉底会话机器人”的教学与直接使用 ChatGPT 的教学。实验将追问式对话、学习分析及翻转课堂结合起来，由机器人引导学生澄清问题、回应提问并继续探究。结果显示，实验条件在部分学习指标上具有优势，但批判性思维的组间差异并不显著。其批判性思维主要采用量表评价，干预也包含多项教学安排。因此，这项研究既提供了连续追问的实现参考，也表明苏格拉底式交互的优势需要在具体任务和结果指标上检验。

赵晓伟等人（2025）针对 44 名教育技术学本科生开展前后测准实验，以认知和元认知支持为基础，设计提示、指导与解释三类苏格拉底式问题支架。研究分析学生向 AI 大模型提问的表现，发现问题深度、问题序列及问题架构得到改善。该研究训练的是学生提出高质量问题的能力，提示了支架可以帮助学习者组织探究过程；其结果主要体现于提问行为，不能直接等同于学生已经能够独立评价论文方法和结论。

胡金艳等人（2026）设计人机协作辩论系统，设置主持、知识提供、学生助手与批判性思维促进等 Agent 角色，并以论证结构组织互动。12 名大学生依次经历基线、单 Agent 与多 Agent 协作阶段，研究对 3,173 条有效对话进行编码及序列、网络分析，发现多 Agent 条件下的思维互动关系更复杂，评价活动在对话中发挥了更突出作用。该研究把支持策略与具体话语表现联系起来，为过程评价提供了依据；固定阶段顺序的设计则主要说明不同条件下的互动特征，尚需独立测验进一步检验能力变化。

国内研究已从使用情况调查推进到提问支架和对话系统设计，但结果并不一致：部分研究观察到提问或对话质量改善，也有研究未发现批判性思维的显著组间差异。这些差异提示，应把干预策略、训练任务与测量对象对应起来。对于科研新手，学生能否在无 AI 条件下识别研究缺陷并解释理由，是比一般使用体验或互动频次更直接的学习结果。

2.3 国外及国际合作相关实证研究

2.3.1 科学论文阅读训练与表现性评价

Lee 等人（2022）在三所美国高校的生物学课程中研究学生阅读原始科学文献的策略，形成包含概括、记笔记和查找信息三个方面的八项自报测量，并比较不同课程阅读安排下的变化。结果显示，策略变化总体有限，且不同支持安排下并非所有策略均有改善。该研究有助于描述新手怎样读论文，但策略自报仍需与实际阅读产出结合，才能判断学生是否理解并有效评价了研究。

Bjorn（2024）在 24 名博士生参加的四周跨学科课程中，将 CERIC 阅读方法与社会协作批注结合。CERIC 要求学生关注主张、证据、推理、意义及情境，课程配合示例与讨论，并以前后测阅读任务评价表现。结果显示，学生在新领域材料上的批判性阅读测验得分提高，自我效能和焦虑也有所改善。该研究说明，明确的分析维度可以落实到论文阅读及评分中；由于未设置平行对照组，其结果反映的是整套教学活动的前后变化。

Archila 等人（2025）在两个食品微生物学课程队列、共 61 名本科生中开展科学文章批判性阅读活动。学生先独立评价材料，再与同伴讨论，最后修订个人回答；活动分别涉及文章引言与方法部分。研究按论证、反论证及反驳的合理性与连贯性评分，发现讨论后的回答有所改善。这项研究将批判性阅读转化为有依据的论证产出，为本研究评价学生理由的质量提供了参考，也说明理解内容之后的讨论与修订值得纳入训练设计。

上述研究采用的结果并不相同：阅读策略问卷关注学生认为自己怎样阅读，阅读测验和论证评分则关注学生实际完成了什么。本研究采用论文任务评价缺陷识别与解释质量，并将概括得分单独记录，以观察内容理解与研究评价的不同变化。

2.3.2 AI 辅助表现与独立学习结果

Stadler 等人（2024）将 91 名大学生随机分配至 ChatGPT 或 Google 搜索条件，要求参与者围绕防晒产品中的纳米颗粒开展科学信息探究并形成有理由的判断。ChatGPT 组报告的认知负荷较低，但最终理由的质量较差。这一结果表明，获得信息更轻松未必带来更充分的证据审查，也提示需要直接评价判断及其论证。

Fan 等人（2025）在 117 名中文母语大学生中比较 ChatGPT、人工专家、写作检查清单和无额外支持四种条件。参与者完成阅读与写作及作品修订，研究同时分析作品、知识学习与过程表现。ChatGPT 支持带来了更大的作文改进，但未在知识获得和迁移上形成相应优势，各组的自我调节学习过程也存在差异。这项国际合作研究进一步说明，评价 AI 支持时应同时考虑有工具的产出和学习者自身获得的知识。

Bastani 等人（2025）在近千名土耳其高中生中开展数学学习随机实验，比较普通 GPT 辅助、带有教学约束的 GPT Tutor 与无 AI 条件。两种 AI 支持均改善了练习表现，但普通 GPT 组撤去工具后的考试表现低于对照组，GPT Tutor 缓解了这一负面结果。该 Tutor 同时使用教师提供的提示、解答及常见错误信息，结果支持教学设计的重要性，但其作用不能全部归于追问。对于本研究，这些发现支持将训练中的帮助与后测独立表现分别测量，并保持两个 AI 组的信息条件一致。

2.3.3 面向论文阅读的 AI 训练系统

Yuan 等人（2023）的 CriTrainer 通过文献与 52 人调查形成设计依据，开发文本概括辅助和批判性提问训练功能。在 24 人的前后测实验中，研究通过撤去工具后的新论文任务，评价概括以及问题的可理解性、相关性和批判性，报告了批判性提问质量的改善。其训练和测量集中于论文引言，说明论文阅读可以通过具体产出评价，但尚未覆盖完整研究的方法与证据审查。

Fang 等人（2026）将 AI 观点交流嵌入论文阅读过程，要求用户围绕章节问题先作答，再查看反馈并修订。其为期两周的研究包含 46 名参与者，比较单一视角、多视角 AI 反馈与无 AI 条件，并设置独立前后测。结果支持观点交流用于促进批判性思考，但未显示多视角反馈稳定优于单一视角。该设计以章节问题和反馈修订组织学习，与根据学生当前理由继续追问的策略有所区别。

这两项研究使论文阅读工具的评价从满意度延伸到独立表现，也提供了不同的训练活动：概括与自主提问、章节作答与反馈修订。本研究进一步围绕学生对研究方法和结论的判断展开连续讨论，既考察能否发现有效缺陷，也考察是否能够说明缺陷成立的理由。

2.3.4 苏格拉底式 Agent 的效果及实现

Xi 等人（2026）在“教育技术研究方法”课程中比较苏格拉底式与非苏格拉底式对话 Agent。94 名学生以小组形式在六周中完成研究方案设计，研究测量研究方法知识、方案质量、反思性思维及动机，并分析对话。苏格拉底条件的研究方案质量和调整后的反思性思维表现更好，学习动机未出现显著组间差异；知识测验的优势随分析方法而异。该研究与本课题的接近之处，在于将追问落实到研究问题、变量、操作定义和方法选择。

该系统包含输入理解、对话生成、动态反馈和结构化记忆，提示由澄清逐步转向理由论证及方案改进。例如，先明确一个变量如何测量，再追问这种测量为什么适合，随后讨论怎样排除先验差异。研究中的两个 Agent 使用不同底层模型，研究方案又是小组产出，因此本研究借鉴其任务化追问与跨轮记忆，并在实验中进一步统一两个 AI 组的模型条件，以个人独立论文评价作为结果。

Namaziandost 和 Teng（2026）比较苏格拉底式 AI、通用 AI 与无 AI 三种条件。90 名中等英语水平学习者参加研究，苏格拉底式 AI 组在批判性思维、认识论信念和论证技能方面获得了更大提升。系统围绕理由、文本证据、替代解释及观点限定进行追问，并借助 Toulmin 模型组织论证内容。这些结果主要来自改编量表与参与者反馈，说明学习者在该教学情境下的自报思维与论证表现有所改善。其设计将追问理由、要求文本证据、提出反例和限定判断联系起来，并根据上轮回应调整后续问题；当学生难以继续时提供提示，能够自主完成时减少支持。

这为本研究提供了两项具体借鉴：一是设置通用 AI 和无 AI 两个比较条件，分别了解教学互动策略与 AI 支持整体的作用；二是围绕学生当前论证选择追问内容，将“为什么这样认为”落实到具体依据、隐含前提和替代解释。其任务发生在外语学习中，本研究将这些设计原则转化为科研论文中的方法与证据检查，并采用实际表现评价结果。

Yurt（2026）在 70 名大学生中开展为期 10 周的 AI 辅助翻转学习研究，报告批判性思维技

能、倾向及动机的改善。其 Socrat.ai 结合自适应追问、跨轮记忆和写作反馈，结果支持这种综合教学安排，但尚不能将效果单独归于某一对话策略。本研究因此保持两个 AI 组的底层模型、材料及工具条件一致，将主要差异设置为教学互动规则。

在实现层面，Shi 等人（2026）的 LFTutor 依据论证内容与学生回应选择教学意图，并记录未解决的分歧，自动评价及 20 名参与者的人类评价主要支持其导师对话质量。Hugenroth 等人（2026）的 Critical Inker 预印本则将论证结构分析、可视化反馈与苏格拉底式对话用于写作，报告技术评价和初步试用结果。这类工作为“理解当前论证—选择追问对象—继续反馈”的实现提供参考，但对话质量与技术指标仍需和独立学习结果分别评价。

2.3.5 相关系统设计与评价的综合比较

已有系统对“支持思考”的实现方式存在差异。CriTrainer 主要把批判性阅读分解为概括与提问活动；Fang 等人（2026）把思考组织为章节问题、作答、反馈与修订；S-ICA、Socrat.ai 和 Namaziandost 与 Teng（2026）的系统更强调持续对话；LFTutor 和 Critical Inker 则进一步将论证分析与下一步对话策略联系起来。这些差异有助于明确本研究究竟要设计哪种交互。

表 1 相关系统的支持方式与验证内容

研究或系统	学习活动与支持方式	主要验证内容	对本研究的设计启示
CriTrainer（Yuan et al., 2023）	概括辅助、关键内容提示、自主提出批判性问题	无工具前后测中的概括及问题质量	用独立阅读产出评价训练，并把理解与评价分开
Fang 等（2026）论文阅读系统	章节问题、用户作答、AI 反馈和修订	两周使用及独立前后测	将讨论与论文具体位置关联，反馈后保留修订机会
S-ICA（Xi et al., 2026）	围绕研究方案的澄清、理由与改进追问	知识、方案、反思量表和对话过程	围绕研究任务组织提示，保留跨轮判断与设计选择
Namaziandost 和 Teng（2026）	理由、证据、反例与限定条件的自适应对话	三组学习比较及量表、访谈	在共同任务下比较三种支持方式，按论证需要调整追问
Socrat.ai（Yurt, 2026）	自适应追问、跨轮记忆和写作反馈	十周课程中的技能、倾向与动机	将追问与反馈结合，联系学生先前的判断
LFTutor（Shi et al., 2026）	论证分析、教学意图选择、策略执行与检查	自动评价、消融及真人对话评价	让策略选择有明确依据，并检查实际回复是否执行该策略
Critical Inker（Hugenroth et al., 2026）	论证结构分析、原文定位、问题计划和对话反馈	技术指标及小规模试用	围绕具体支持关系展开讨论，避免连续重复已回答的问题

这些研究也说明，系统评价需要覆盖不同层面。论证抽取准确、追问策略执行稳定，是系统能够正常工作的条件；用户愿意讨论、认为提示清楚，是可用性和体验证据；学生撤去工具后能否独立发现并解释研究缺陷，则需要单独的学习实验。本研究将这三类工作分别安排到产品开发、可用性测试和效果实验之中。

2.4 Agent 设计的理论依据

2.4.1 生成性学习与自我解释

生成性学习强调学习者主动建立意义。Wittrock（1974/2010）指出，理解涉及学习者在材料各部分之间、以及材料与已有知识之间生成联系。Fiorella 和 Mayer（2016）进一步从选择、组织和整合信息的角度解释生成性学习活动：学习者选择重要内容，将其组织成有意义的关系，并与已有知识联系起来。

自我解释是实现这种加工的一种活动。学习者为自己解释材料中的关系、原理或推理过程，补充文本没有直接说明的联系，并修正原有理解。Chi 等人（1994）通过提示学生进行自我解释，发现其文本理解优于未接受相应提示的条件；Chi（2000）进一步从生成推论和修复心理模型两个过程解释自我解释的作用。

在科研文献评价中，学生说“分组不合理”只表达了结论；如果进一步说明“参与者自行选择是否接受干预，原有动机可能同时影响分组和结果，因此观察到的差异不能直接归因于干预”，就建立了研究做法、方法学原则和推断结果之间的联系。本研究拟通过“原文依据在哪里”“这一做法为什么影响结论”“还有什么解释可能成立”等问题，引导学生完成这些联系。Agent 随后根据学生生成的解释继续提供反馈，使学生有机会完善推理。

生成性学习与自我解释之间可以理解为总体加工要求与具体学习活动的关系。选择、组织和整合说明学习者需要怎样处理信息，自我解释则让学习者把这些联系表达出来。例如，在阅读一项自愿参加的培训研究时，选择是注意到分组方式和结果差异，组织是把两组的形成过程与比较结果联系起来，整合则是运用已有的混淆变量知识解释为什么差异未必由培训造成。

这种解释能够由问题引发。Agent 询问“除了培训，还有什么可能造成两组成绩不同”，使学生从结果描述转向替代解释；继续询问“你为什么认为这个因素会同时影响参加培训和考试成绩”，则要求学生把替代解释的作用路径说清楚。如果学生随后发现自己把观察到的差异直接当成了因果作用，并据此修改判断，就发生了对原有理解的修正（Chi, 2000）。

表 2 生成性加工与追问设计的对应

生成性加工	科研论文阅读中的表现	Agent 如何引导	可观察的学生回应
选择重要信息	识别与当前结论有关的方法、结果或限制	询问判断针对哪项结论、原文依据在哪里	指出相关段落、变量、比较条件或结果
组织信息关系	联系研究问题、做法、证据与结论	询问某项做法如何影响证据或推断	说明信息之间的支持、限制或矛盾关系
整合已有知识	运用方法学原则解释具体研究	询问为什么适用某条原则、适用条件是什么	把研究情境与概念或原则连接起来
生成推论和修正理解	补出隐含前提，比较替代解释，调整结论	追问未说明的前提、可能反例及修正理由	提出有依据的新联系并说明判断为何变化

对自我解释的观察以学生是否生成了理解所需的联系为重点。单纯重复 AI 刚给出的结论、复述论文原句或增加发言长度，都可能没有补充新的推理。因而，Agent 在反馈时需要关注学生

具体建立了什么关系，在过程分析中也要区分自主生成、提示后生成和复述 AI 内容。研究通过这一对应关系，将学习理论转化为可执行的追问目标。

2.4.2 最近发展区与自适应支架

Vygotsky（1978）用最近发展区描述学习者当前独立完成的水平与在适当指导或合作下能够达到的水平之间的距离。这一观点启发本研究根据学生实际困难调整支持程度。当学生已有判断但理由不足时，可以通过追问保留其自行推理的空间；当学生缺少必要概念时，应先提供讲解；当学生已能定位依据并说明关系时，则减少相应提示。

本研究将这一原则落实为开放引导、方向提示、具体支持和必要讲解四种帮助程度。Agent 根据回应与求助调整支持，而不要求每次对话依次经过所有层级。帮助的目标是使学生能够继续分析和解释，并逐步承担原先需要支持才能完成的活动。

在本研究中，自适应主要体现为对帮助程度的调整。一个学生可能已经知道研究是观察性的，却不清楚这一点对因果解释意味着什么；另一个学生可能连“随机分配”与“随机抽样”都尚未区分。前者适合被追问推断依据，后者需要先获得概念说明。依据学生的实际回应选择支持，可以让讨论集中在当前可推进的问题上。

帮助程度也随同一学生的讨论进展变化。最初需要 Agent 定位方法段落的学生，后续若已经能够自行查找相关信息，系统就不再重复提供定位线索；对于已经解释清楚的关系，系统确认后转向新的疑问。最近发展区在此提供调整支持的理论原则，四级帮助及停止规则是本研究结合阅读任务提出的具体实现方案。

2.4.3 Toulmin 论证模型

Toulmin（2003）的论证模型区分主张、依据、连接依据与主张的论证理由、对理由的支持、限定条件与反驳。它为检查“有什么证据”“证据为什么支持判断”“判断在什么条件下成立”提供了具体框架。

本研究将该模型用于组织追问内容，并辅助判断下一步教学动作。Agent 首先区分作者的研究主张与学生对论文的评价，再检查当前论证中需要澄清的部分。例如，对“这个样本太小，所以研究无效”的评价，可以先询问学生认为哪种推断受到影响，再讨论样本量、估计不确定性与结论强度之间的关系。论证模型由此将笼统的“批判性提问”转化为针对依据、推理和边界的追问。

Toulmin 模型也帮助区分两层论证。一层是作者如何从研究结果提出结论，另一层是学生如何依据文章信息评价作者的结论。Agent 首先确认当前讨论对象，再分析该层论证中需要检查的联系。例如，作者认为培训提高成绩，学生则认为这一因果判断证据不足。此时系统既要帮助学生准确理解作者的证据，也要检验学生提出的批评本身是否成立。

表 3 Toulmin 论证成分与论文评价

论证成分	在论文评价中的含义	需要解释的关系
主张（Claim）	作者的研究结论或学生的评价判断	当前到底在肯定、否定或限定什么

依据（Data/ Grounds）	方法、数据、结果及文中的具体陈述	哪些文章信息支持这一判断
论证理由（Warrant）	把依据与主张连接起来的推断原则	为什么这些信息能够支持或限制结论
支持（Backing）	使方法原则合理且适用的知识	为什么该原则适用于当前研究情境
限定（Qualifier）	结论的范围、强度和条件	评价应当限定到什么程度
反驳或例外（Rebuttal）	替代解释、反证及可能改变判断的情形	在什么情况下当前判断需要修改

本研究把这些成分作为理解学生论证和选择追问的参照。对于已经说明依据的回答，下一步可集中在依据与结论的联系；对于理由完整但结论过强的回答，则讨论限定条件。这样的策略选择可以记录为当前讨论对象、已有依据、待澄清关系与拟采取的教学动作，并由模型生成自然语言回复。论证成分服务于对话推进，学生无需先学习整套术语再开始阅读。

三项理论依据承担相互衔接的作用：生成性学习与自我解释说明希望学生完成什么加工；最近发展区指导帮助程度的调整；Toulmin 模型规定需要检查和讨论哪些论证关系。本研究据此形成 Agent 设计，并通过独立任务表现与对话过程记录考察设计效果。

2.5 研究述评与本研究问题

现有研究为本课题提供了三方面基础。科学论文阅读研究已将概括、论证和自主提问转化为可观察产出；AI 辅助学习实验说明，工具支持下的表现与独立学习结果可能不一致；苏格拉底式 Agent 研究则提供了围绕依据、前提和替代解释展开互动的设计思路。

需要进一步研究的是，连续追问在科研论文评价这一任务中能否改善学生的独立表现。现有研究涉及外语、数学、议论文写作和科学信息探究，论文阅读工具多以引言提问或章节回答为训练活动，对完整研究中缺陷识别及其解释质量的联合考察仍较有限。与此同时，已有苏格拉底式支持研究的结果并不完全一致，量表、对话编码及任务测验又分别反映不同层面的变化，需要通过明确的任务和对照条件进一步检验。

本研究据此将问题落实为：如何围绕论文原文、方法学原则及学生当前判断形成连续而适度的追问；这种支持相较于通用 Agent 和独立阅读，能否改善撤去 AI 后的缺陷识别与解释质量。研究依次开展设计依据与需求分析、Agent 开发与可用性测试及三组效果实验，并探索初始批判性思维倾向与训练收益的关系。

二、研究方案

1．研究目标、研究内容和拟解决的关键问题

1.1 研究目标与研究内容

本研究旨在设计一款面向科研新手的苏格拉底式文献阅读 Agent，并检验其对独立文献批判性评价表现的影响。研究包括三个相互衔接的部分。研究一通过文献梳理、同类工具比较和小规模半结构化访谈，明确理论依据及阅读中的实际困难；研究二将设计要求转化为 Agent 和阅读界

面，开展两轮可用性测试并迭代；研究三通过预实验完善材料、流程和评分手册，再比较三种辅助方式的训练效果。

研究内容按照设计形成、产品实现和效果验证三个阶段组织。每一阶段形成下一阶段所需的具体产出，研究三使用经过前两个阶段完善的 Agent 版本。

表 4 三个研究的内容与阶段产出

研究	主要研究内容	采用的方法	阶段产出及用途
研究一：设计依据与需求分析	梳理支持科研新手评价论文的理论与系统，了解真实阅读中的困难和支持需要	文献梳理、同类工具比较、6—8 人半结构化访谈	形成设计依据、典型困难和功能要求，指导 Agent 规则与界面设计
研究二：产品开发与可用性测试	将追问内容、帮助程度和跨轮讨论规则转化为可运行系统	原型与 Agent 开发、两轮各 5—6 人的可用性测试	形成正式实验可用的系统、交互规范及迭代记录
研究三：效果实验	检验三种辅助方式对独立缺陷识别、解释质量和概括表现的影响	4 人预实验、三组随机前后测实验、盲评及统计分析	形成独立表现证据、过程描述及产品设计建议

1.2 拟解决的关键问题

（1）把理论要求转化为适合论文阅读的互动规则。生成性学习要求学生主动建立信息联系，但实际阅读中的困难可能来自内容理解、原文定位、方法知识或推理本身。本研究需要明确 Agent 如何判断当前讨论对象，何时追问依据和理由，何时先解释概念，并依据回答调整支持。

（2）在自主阅读中维持有意义的讨论。训练没有统一题单，学生可能带着不同的疑问进入对话，也可能不知道从哪里开始。系统需要接住这些入口，联系先前已经形成的判断，避免反复询问相同内容，并允许用户请求更多帮助、切换问题或结束讨论。

（3）形成可比较的训练条件。三组都完成相同研读任务，两个 AI 组共享模型、信息和基础界面，通过教学互动规则形成区别。研究需要同时保持材料、训练时长及前后测条件一致，使结果能够回答不同辅助方式的训练效果。

（4）建立与任务对应的评分和分析方法。缺陷识别需要判定批评是否具体成立，解释质量则需要检查依据与推理。研究将结合材料评析、专家核对及评分者试评确定标准，分别报告发现比例、解释质量与精确率，并通过前测调整比较独立后测表现。

1.3 研究问题与假设

RQ1：苏格拉底式 Agent 辅助阅读能否提升科研新手在撤去 AI 后的文献批判性评价表现?

H1a：控制对应前测及材料顺序后，苏格拉底式 Agent 组的后测缺陷识别击中率高于通用 Agent 组。

H1b：控制对应前测及材料顺序后，苏格拉底式 Agent 组的后测缺陷识别击中率高于无 AI

组。

H1c：控制对应前测及材料顺序后，苏格拉底式 Agent 组的后测平均解释质量高于通用 Agent 组。

H1d：控制对应前测及材料顺序后，苏格拉底式 Agent 组的后测平均解释质量高于无 AI 组。

缺陷识别假设关注学生能否将阅读注意进一步转向影响研究推断的具体信息。苏格拉底式 Agent 围绕主张、依据和替代解释展开检查，在学生遇到困难时提供适量提示，预计能够增加其练习发现问题和核对问题的机会。独立后测将观察这些练习是否体现为更多有效缺陷的识别。

解释质量假设关注学生是否能够把研究做法、方法原则及其对结论的影响连成推理。通用 Agent 可以直接提供解释，独立阅读则由学生自行组织思考；苏格拉底式 Agent 持续要求学生先说明理由，再根据反馈补充与修正。依据自我解释研究，这种生成和修正联系的活动可能促进理解（Chi et al., 1994; Chi, 2000），从而提高后测中解释已识别缺陷的质量。

RQ2：不同辅助方式是否影响科研新手对论文内容的理解表现？本研究控制前测概括得分与材料顺序，比较三组后测论文内容概括表现，不预设组间差异方向。

RQ3：初始批判性思维倾向是否调节苏格拉底式 Agent 相对通用 Agent 的训练效果？该问题作为探索性分析。H3a：初始倾向越低，苏格拉底式 Agent 相对通用 Agent 在后测缺陷识别击中率上的优势越大。H3b：初始倾向越低，苏格拉底式 Agent 相对通用 Agent 在后测平均解释质量上的优势越大。其依据是，主动追问可能为较少自发检查依据和理由的学习者提供额外支持。初始倾向较高的学生可能在一般帮助或自主阅读中也会主动寻求证据，因此追问带来的额外收益可能不同。研究以连续倾向得分检验这一预期，探索性结果用于描述哪些学习者更可能受益。

表 5 研究问题与测量指标的对应

研究问题	对应结果	主要比较或检验
RQ1：独立批判性评价能否改善	缺陷识别击中率、平均解释质量	每个指标比较苏格拉底组与通用组、无 AI 组，对应 H1a—H1d
RQ2：内容理解是否受到影响	论文内容概括表现	控制前测概括得分后比较三组后测
RQ3：初始倾向是否影响收益	两个主要结果与 CCTDI 总分	检验苏格拉底组相对通用组的优势是否随初始倾向变化，对应 H3a、H3b

2．拟采取的研究方法（或技术路线、实验方案）、安全论证及可行性分析

2.1 总体技术路线

本研究采用“设计依据与需求分析—产品开发与可用性测试—效果实验”的路线。前两项研究用于形成并完善干预工具，第三项研究用于检验训练效果。各阶段使用统一的目标用户定义，并将材料、界面、交互规则及测量工具在正式实验前固定。

2.2 研究一 设计依据与需求分析

2.2.1 研究目的与方法

研究一旨在明确科研新手在理解并评价论文时需要什么支持，以及这些支持怎样转化为 Agent 设计。前期已完成相关理论及主要系统文献的初步梳理，下一步将整合同类工具比较与小规模访谈，形成设计要求。文献用于确定学习活动及追问原则，工具比较用于了解已有实现，访谈则用于核对这些原则在真实阅读情境中应该怎样呈现。

文献梳理围绕三类问题进行：科研论文评价如何被定义和测量；追问、反馈及自适应帮助怎样引导学习者生成解释；现有 AI 系统通过何种实验验证学习效果。对于每项研究，记录任务对象、支持方式、参与者、比较条件、测量及结论，并把结果与本课题的具体任务对应起来。

2.2.2 同类工具比较

选取 CriTrainer、Fang 等人（2026）的论文阅读系统、S-ICA、LFTutor、Critical Inker 等具有不同支持方式的研究原型进行比较。比较以论文、附录、演示及可获得的系统信息为依据；具备访问条件时，在相同类型阅读问题下体验交互，记录实际操作。对仅能通过论文了解的系统，以其公开设计为分析对象。

表 6 同类工具比较维度

比较维度	具体记录内容	对本研究的用途
用户与任务	面向谁，训练概括、提问、论证还是研究设计	确定科研新手论文评价任务的范围
材料与上下文	能读取全文、选中文本、图表或用户笔记中的哪些内容	确定 Agent 接入信息及原文定位方式
对话入口	由章节问题、用户疑问、已有判断或预设活动启动	设计多种进入讨论的方式
追问与反馈	怎样根据回答继续追问，何时给解释或直接反馈	形成教学动作与选择规则
帮助调整	是否区分开放问题、方向提示和具体线索	形成自适应帮助层级
跨轮记录	是否保留已解释内容、分歧及未解决问题	减少重复，支持连续讨论

用户控制	是否支持求助、暂停、跳过和返回原文	明确节奏控制与退出入口
评价方法	系统性能、使用体验、学习过程及独立结果分别怎样测	确定开发测试和效果实验的分工

工具比较将形成“设计做法—证据来源—本研究采用方式”的记录。例如，LFTutor 的策略选择与检查提供实现思路，CriTrainer 的独立前后测提供评价思路，而章节问题系统提供原文定位与反馈修订的界面参考。比较结果与访谈共同用于确定优先实现的功能。

2.2.3 参与者招募与访谈准备

计划招募 6—8 名心理学或应用心理学专业学生，范围为大学二年级及以上本科生和硕士一年级学生。参与者须年满 18 周岁，能够熟练阅读中文，具备心理统计、研究方法或相当课程基础，科研实践经验有限。招募时记录其年级、课程、论文阅读及 AI 使用经历，以覆盖不同的阅读困难和求助方式。

访谈采用结合真实论文和阅读记录的半结构化形式，每人约 35—40 分钟。预约时邀请参与者准备一篇近期读过且曾遇到理解或评价困难的实证论文，并选择愿意展示的笔记、批注或 AI 聊天记录。没有现成记录者，可以结合论文回忆具体过程。材料由参与者自主选择，研究者只收集与阅读支持有关的信息。

2.2.4 访谈流程与提纲

访谈从一次具体阅读经历展开，追问当时的目标、阅读顺序、困难、处理行动及处理后的变化。研究者结合原文和记录定位情境，了解参与者为什么停顿、为什么请求 AI 帮助，以及获得回复后做了什么。

表 7 半结构化访谈流程

环节	参考时长	主要内容
阅读背景	约 5 分钟	了解课程基础、科研经历、平时阅读任务及 AI 使用情况
回顾具体经历	约 10 分钟	围绕准备的论文重述阅读过程，定位困难及当时采取的行动
讨论关键困难	10—15 分钟	追问内容理解、证据定位、评价形成与理由说明中的问题
讨论支持方式	5—8 分钟	结合具体情境了解需要解释、提示还是追问，以及希望怎样控制节奏
确认与补充	约 2 分钟	确认主要困难和未解决问题，补充遗漏信息

各环节根据实际材料适度调整，使总时长保持约 35—40 分钟。提问以开放问题为主，必要时请参与者指出对应段落或展示当时的操作记录。

表 8 访谈提纲及对应设计决策

关注点	访谈问题示例	对应设计决策
阅读目标与过程	当时为什么读这篇？先看了哪里，后来为什么跳到这里？	Agent 如何了解当前任务，怎样衔接原文与对话
内容理解困难	这里当时哪里没看懂？后来怎么弄懂的？	哪些情境需要先解释术语、概念或研究步骤
研究判断形成	为什么认为这里有问题或没有问题？哪些信息支持这个判断？	怎样接住用户已有判断并追问依据
推理中的困难	从这些信息到判断，中间哪一步最拿不准？	是追问推理联系，还是补充方法知识
核对与修正	有没有回看其他部分或改变判断？是什么促成变化？	怎样支持原文核对、替代解释与判断修正
AI 帮助的使用	看完这段回复后，你接着做了什么？还有什么没解决？	现有回复是否帮助用户继续分析
帮助程度与节奏	如果当时先问一个问题，你能继续吗？还需要什么支持？	何时给方向、具体线索、讲解或结束讨论

2.2.5 资料分析与设计要求形成

经参与者同意录音并转写，将具体经历整理为“困难发生的情境—已有处理方式—仍缺少的支持”。分析时既关注共同困难，也保留差异。例如，同样表示“看不懂方法”，有的参与者缺少概念知识，有的则理解术语但不能把方法与研究问题联系起来，两种情况需要不同支持。

表 9 阅读困难的辨别与支持方式

候选困难	需要进一步辨别的情况	可能对应的支持
看不懂术语和方法	缺少基础知识，还是文章表达不清	概念解释、句子澄清或研究步骤说明
找不到相关信息	不知道在哪里找，还是找到后仍不理解	原文定位或联系上下文解释
不知道如何评价	缺少检查方向，还是知道原则却不会应用	中性方向提示或方法适用性追问
提出批评但说不清理由	推理尚未建立，还是已有理解但表达困难	追问推理联系或帮助整理已有解释
不知道批评是否成立	是否核对原文、寻找反证或寻求帮助	证据检查、替代解释和判断限定
阅读中断或负担过高	材料太难、信息过多，还是追问打断阅读	调整帮助程度、回复长度及控制入口

以上类别作为初步分析线索，编码中保留新出现的困难与支持需要。先整理每位参与者的完整事件，再跨参与者比较，以原话和具体行为支持主题。对于能够直接指导设计的问题，记录其

发生情境、当前解决方式和仍未解决的部分。

例如，参与者如果表示“我知道相关不等于因果，但不知道这篇研究是否已经排除了其他解释”，可形成“帮助核对具体控制条件，并要求解释其作用”的设计要求。该例仅说明分析方式，实际设计要求根据访谈材料形成。最终产出包括目标用户特征、典型阅读困难、设计依据表和功能优先级，交由研究二实施。

2.3 研究二 Agent 开发与可用性测试

2.3.1 产品定位与基本功能

系统提供统一论文阅读区、原文定位、标注与笔记、对话讨论及历史记录。用户可以发送选中文本或自己的判断，也可以直接提出理解问题。Agent 可访问论文全文、统一译文、图表、段落编号、通用方法学原则、当前用户的对话历史和主动发送的内容。文章配套专家评析、预设缺陷清单和评分答案单独保存，不输入 Agent。

通用 Agent 与苏格拉底式 Agent 采用相同模型版本、材料访问条件、生成参数和工具权限，并使用相同阅读界面。通用 Agent 按用户请求解释、总结、答疑和分析；苏格拉底式 Agent 增加围绕学生判断持续追问及调整帮助的规则。

系统以论文为主要操作对象，用户阅读原文时可选中相关句段并发送至对话区，也可直接输入判断或疑问。对话中的原文引用携带段落编号，便于返回上下文核对；笔记和批注保留用户自己的理解与疑问。系统记录当前讨论涉及的结论或研究做法，帮助用户在阅读与讨论之间切换。

表 10 两个 Agent 的信息与功能条件

输入或功能	通用 Agent	苏格拉底式 Agent
论文全文、统一译文和图表	相同	相同
段落编号与引用定位能力	相同	相同
通用方法学原则	提供同一份参考材料	提供同一份参考材料
当前用户对话、主动发送的选中文本和笔记	可访问范围相同	可访问范围相同
专家评析、预设缺陷清单和评分答案	不提供	不提供
联网或外部检索	正式实验版本与另一组保持一致；初版关闭外网检索	同左
教学互动规则	按请求提供解释、总结、答疑和分析	分析当前论证，自适应追问并提供必要帮助

教学规则与材料内容分别配置。更换文章时，系统载入新的全文、图表和段落编号，继续使

用相同的论证检查与帮助原则。配套专家评析用于研究者准备评价材料和评分，Agent 依赖论文内容与通用方法知识和学生讨论。

2.3.2 从理论到交互规则

表 11 理论依据与交互规则的对应

理论或框架	设计中的作用	具体交互安排
生成性学习与自我解释	促使学生组织信息，并连接研究做法、方法原则与结论	追问依据为什么支持判断，保留关键推理让学生完成，再依据回答反馈
最近发展区与自适应支架	根据当前困难调整帮助程度	在开放引导、方向提示、具体支持和必要讲解之间调整，能够自主完成时减少提示
Toulmin 论证模型	组织追问内容，分析论证中尚不清楚的联系	检查主张、依据、论证理由、支持、限定条件与反驳

Agent 从三类常见入口接住学生：对不理解的术语、句子或步骤，先帮助澄清内容；对已有判断，检查依据、推理联系和结论边界；对不知道从哪里开始的情况，邀请用户选择一处结论或不确定之处，仍有困难时提供中性的检查方向。

表 12 学生进入讨论的方式

学生进入讨论的方式	Agent 如何回应	讨论如何继续
不理解内容	解释术语、句子或研究步骤，并关联原文	理解得到澄清后，按需要联系到研究判断
已经形成判断	确认判断对象，检查原文依据和推理联系	针对尚不充分的关系追问，讨论结论边界
不知道从哪里开始	邀请选择一处结论或不确定之处；仍困难时提供中性检查方向	从选定问题开始检查依据，逐渐形成自己的判断

Toulmin 模型用于引导 Agent 把问题问具体。主张不清时，询问“你认为作者的哪一项结论支持不足”；依据缺失时，询问“文章中哪些信息支持你的判断”；理由未展开时，询问“这项研究做法为什么影响该结论”；原则适用性不清时，询问“你依据的方法原则适用于这里的哪些条件”；判断过强时，询问“这会使结论完全不成立，还是需要缩小结论范围”；存在其他可能时，询问“有没有与这些结果同样相容的解释”。Agent 结合当前对话选择相关问题。

下表把学生表现、教学动作与希望诱发的自我解释对应起来，作为 Agent 提示规则和后续交互检查的依据。

表 13 学生表现、教学动作与生成性加工

学生当前表现	Agent 的教学动作	希望学生完成的加工
作出判断但没有依据	追问相关原文及其作用	把判断与具体信息联系起来

有依据但缺少推理联系	追问依据为什么支持判断	补出证据与结论之间的推理
判断依赖未说明的前提	询问结论成立需要满足的条件	将隐含前提明确化
机械使用方法学原则	追问原则的含义及在本研究中的适用性	把方法知识与具体情境整合
只考虑一种解释	邀请提出其他解释，并核对是否与证据相容	比较解释并检查原有判断
发现矛盾后改变判断	请学生说明修正内容与理由	修复原有理解并形成更充分的解释
已经给出充分解释	确认其依据和推理，允许结束或转向下一问题	保留已完成的思考，避免重复

2.3.3 自适应帮助与每轮流程

帮助程度分为四类。开放引导仅提出问题，让学生自行选择依据或组织解释；方向提示缩小检查范围；具体支持指出有关段落、图表或需要比较的信息；必要讲解解释所缺概念或示范局部推理，仍无法推进时可直接解释当前问题。

表 14 自适应帮助程度

帮助程度	Agent 提供什么	学生保留的任务
开放引导	提出问题，不指定检查方向	自行选择依据并组织解释
方向提示	缩小检查范围，如关注组间可比性	判断哪些信息有关，说明其作用
具体支持	指向有关段落、表格或需要比较的信息	完成关键推断并形成评价
必要讲解	解释所缺概念、示范局部推理；必要时直接解释当前问题	结合文章理解讲解，尝试重新组织判断

帮助程度与追问内容共同决定本轮回复。例如，系统决定讨论“替代解释”后，可以开放地请学生提出其他可能，也可以在其求助后提示比较分组前的特征。对于需要解释术语的学生，先澄清术语再继续分析。

当学生明确求助或回答持续没有推进时，Agent 增加帮助的具体程度；明确存在知识缺口时，可直接提供讲解；学生已经能够自主定位依据或建立推理联系时，减少相应提示。解释已经充分、现有信息不足以继续判断，或用户希望跳过和结束时，停止当前追问。界面提供请求提示、请求讲解、切换问题和结束讨论的入口。

每轮交互依次完成：确定当前讨论的作者主张、研究做法或学生评价；结合原文核对理解和依据；识别需要澄清的论证关系；选择澄清、追问、提示、讲解、确认或结束；确定帮助程度；生成并检查回复；更新讨论记录。回复原则上围绕一个主要问题展开，记录保存已形成的判断、依据、解释、已提供的帮助及未解决的问题。

表 15 Agent 每轮交互流程

每轮环节	主要工作	形成的记录
确定讨论对象	明确涉及的作者结论、研究做法或学生评价	当前主题、相关段落与用户意图
核对理解和依据	检查原文是否支持当前理解，必要时先澄清	已确认信息与待核对信息
分析当前论证	判断主张、依据、理由或限定条件中哪部分需要推进	已有论证及待澄清关系
选择教学动作	在澄清、追问、提示、讲解、确认和结束之间选择	本轮动作及选择依据
确定帮助程度	根据回答、求助和已有提示调整支持	当前帮助层级与已提供线索
生成并检查回复	生成自然语言，核对事实、引用及策略执行	最终回复、引用位置及检查结果
更新讨论状态	保存学生新生成的解释、修正和未解决问题	后续对话可用的跨轮记录

实现上设置输入理解、自适应策略选择、跨轮记忆及事实与交互检查四个模块。策略选择与自然语言生成相衔接，使追问对象、支持程度及停止条件能够被记录与检查。事实检查结合原文定位核对引用，交互检查关注误读、附和、重复追问及过度提示。

2.3.4 交互示例与开发检查

以下以假设性的培训研究说明交互：文章报告，自愿参加培训者的考试成绩高于未参加者，并据此作出培训提高成绩的结论。示例展示追问如何随学生回应变化，开发时将用不同文章和不同回答检验同一规则。

表 16 苏格拉底式对话示例

对话进展	回复或行动示例	设计意图
学生接受作者结论	学生：“培训组分数更高，说明培训有效。”	确认学生已经形成判断
Agent 核对依据	“文章中的两组是怎样形成的？这与你刚才的判断有什么关系？”	引导关注与因果判断有关的方法信息
学生找到分组信息	学生：“是学生自己决定是否参加，但我不知道这有什么影响。”	识别其已有依据而缺少推理联系
Agent 给方向提示	“参加之前，两组可能在哪些方面就不一样？这些差异会影响考试成绩吗？”	缩小范围，保留替代解释让学生生成
学生生成解释	学生：“愿意参加的人可能本来就更有动力，动力也可能让成绩更高。”	把分组方式、第三变量与结果联系起来

Agent 追问判断边界	“如果存在这种可能，你会怎样修改‘培训提高了成绩’这个说法？”	引导区分观察差异与因果结论
学生修正判断	学生：“现在只能说明参加者成绩更高，还不能确定差异来自培训。”	形成有理由且有限定的评价

如果学生在上述过程中无法理解混淆变量，系统可以先作必要讲解，再请其结合文章说明影响；如果学生已经完整指出选择差异及因果限制，系统则确认后结束当前话题。对话结束记录包括学生最终判断、依据及仍有疑问的部分。

开发检查围绕输入理解、事实准确性、策略执行及跨轮连续性展开。研究者准备包括术语求助、理由不足、错误批评、完整解释和主动结束在内的测试情境，检查 Agent 能否采用相应动作。对原文不存在的信息、误解图表、无依据赞同、连续重复及用户已结束仍追问等情况，记录触发输入和修改结果。

表 17 开发检查情境与预期表现

检查情境	预期表现	调整方向
用户请求基础概念解释	给出与原文有关、便于理解的说明	修改入口识别与概念解释规则
用户判断正确但理由不足	围绕缺失关系继续追问	明确当前推理目标，减少泛泛提问
用户提出不成立的批评	回到原文检验依据及方法原则	改善事实核对，避免直接附和
用户已经充分解释	确认并允许转向下一问题	完善结束条件与记忆更新
用户多次求助	提供更具体线索或必要讲解	调整帮助层级的选择
用户切换或停止讨论	执行其选择并保留已有记录	完善用户控制与状态切换

完成上述检查后进入可用性测试，根据真实使用进一步修订交互。正式实验前固定两个 Agent 的版本、系统提示及共同信息条件，保存配置与变更记录。

2.3.5 可用性测试

拟开展两轮可用性测试，每轮招募 5—6 名符合目标用户特征的参与者，第二轮优先邀请新参与者。第一轮发现理解、操作和互动中的问题，修改后由第二轮复查。测试每人约 45—55 分钟，包括说明与背景了解 5 分钟、操作熟悉 3—5 分钟、阅读与讨论 25—30 分钟、系统可用性量表（SUS）约 3 分钟及回顾访谈 10—12 分钟。

参与者阅读适合其基础的实证论文，自由使用 Agent 理解内容、讨论判断和核对依据。研究者记录操作成功、错误与求助，重点观察追问是否清楚、是否匹配当前困难、提示是否合适、跨轮讨论是否连贯，以及用户是否能够控制节奏。结束后结合操作和对话片段访谈，并使用 SUS 评价总体可用性。SUS 采用 10 项标准计分方法，汇总为 0—100 分（Brooke, 1996）。

表 18 可用性测试观察内容

测试方面	重点观察	主要资料
阅读与对话操作	能否找到段落、发送选中文本、查看回复并返回原文	操作成功、错误、求助及录屏
追问可理解性	是否明白问题并知道怎样回应	澄清请求、答非所问与回顾说明
追问与困难的匹配	需要解释时是否得到解释，有判断时是否围绕依据讨论	对话片段与访谈
帮助程度适切性	提示是否过于笼统、直接或冗长，卡住时是否得到支持	停滞、重复提问、请求讲解
对话连续性	是否联系已经表达的判断，避免重复追问	跨轮记录与用户反馈
节奏与控制	能否请求提示、讲解、切换或结束	操作记录与回顾访谈
总体可用性	系统是否易于学习和使用	SUS 及开放意见

回顾访谈结合刚才的具体片段进行，如“看到这个问题时，你认为需要回答什么”“这里为什么想让 Agent 直接解释”“这轮回复有没有帮助你继续看原文”。研究者将主观评价与实际操作联系起来，判断问题来自界面、话语表达还是教学策略。

分析时将问题整理为“发生情境—行为或原话证据—修改方案—复查结果”，按其对阅读与思考的影响确定优先级。比较两轮问题是否解决，报告 SUS 描述结果与访谈主题，形成可进入效果实验的系统版本。

2.4 研究三 效果实验

本研究考察不同 Agent 辅助方式对科研新手独立阅读表现的影响。自变量为 Agent 辅助方式；因变量为论文内容概括表现和批判性评价表现；初始批判性思维倾向为探索性调节变量。通过统一参与者资格、材料与任务、时间、工具及评分程序控制无关因素，并在统计分析中调整对应前测得分和材料顺序。各变量的定义、操纵与测量方法分别说明如下。

2.4.1 设计与参与者

采用三组随机分配、前后测的实验设计。自变量为 Agent 辅助方式，包含无 AI 独立阅读、通用 Agent 辅助阅读和苏格拉底式 Agent 辅助阅读三个水平。计划通过校园及院系渠道招募 100 名参与者，目标获得 90 名有效参与者，每组 30 人，其余 10 名作为未完成或无效数据的招募余量。采用随机分配，使三组人数尽量均衡；以每组 30 名有效参与者为目标，各组内 A→C 和 C→A 两种前后测材料顺序各安排 15 人。全部符合标准的有效数据均纳入分析。

参与者为心理学或应用心理学专业大学二年级及以上本科生和硕士一年级学生，年满 18 周岁，能够熟练阅读中文，已修读并通过心理统计、实验心理学或研究方法、心理测量等相关课程或内容相当课程。除常规课程练习外，参与者尚未实质承担研究方案设计、数据分析或研究报告撰写等核心科研工作；仅从事招募、录入等辅助工作者可纳入并记录经历。排除已阅读实验文章

或其评析、参加过本研究预实验者。

样本量围绕四项主要比较进行规划。参考回归模型中增量效应的功效分析方法（Faul et al., 2009），设预期组间标准化差异 d = 0.80、前后测相关 r = 0.50、统计功效为 0.80，并按四项比较采用 α = 0.0125 进行保守规划，估算需 84 名有效参与者。在该估算基础上，将目标有效样本量取整为 90 人，每组 30 人；考虑约 10%的无效或未完成情况，计划招募 100 人。该规划针对较大效应，正式分析采用 Holm 校正并报告效应量及置信区间；初始倾向的调节作用作为探索性问题。

招募通过院系通知、学生社群及校园渠道进行，预约前使用筛选表核对课程与科研经历。筛选内容包括是否接触过候选论文、是否读过配套评析，以及是否能够完成提前测量和训练当天两个场次。符合条件者进入随机分配，保留分配记录与实际完成情况。

每组内同时安排两种测验材料顺序：一部分前测 A、训练 B、后测 C，另一部分前测 C、训练 B、后测 A。这样，A 和 C 在各组都同时承担前测和后测材料，避免某一组固定遇到较容易的后测文章。分析中纳入材料顺序，并报告各组实际分布。

表 19 随机分组与材料顺序

组别	前测顺序一	前测顺序二	训练材料及支持	后测
无 AI 组，目标有效 30 人	A，目标 15 人	C，目标 15 人	B，独立阅读	分别为 C 或 A，独立完成
通用 Agent 组，目标有效 30 人	A，目标 15 人	C，目标 15 人	B，通用 Agent 辅助	分别为 C 或 A，独立完成
苏格拉底式 Agent 组，目标有效 30 人	A，目标 15 人	C，目标 15 人	B，苏格拉底式 Agent 辅助	分别为 C 或 A，独立完成

样本量规划对训练效应大小较为敏感。在相同的前后测相关、功效和四项比较规划下，若预期 d = 0.50，需要约 204 名有效参与者；d = 0.60 需要约 144 人；当前 d = 0.80 的估算需 84 名有效参与者，本研究按 90 名有效参与者规划。研究将同时报告实际差异与区间，结合预实验检查测量是否能够区分不同水平的表现。100 人为计划招募数，90 人为目标有效数，符合预定要求的数据均纳入分析。

2.4.2 材料准备与预实验

从 Meltzoff 和 Cooper（2018）的模拟研究文章中选择候选 A、B、C：B 用于训练，A 和 C 用于前后测。材料匹配考虑篇幅、研究方法知识要求、研究结构、缺陷类型及数量。文章均提供统一译文、排版和图表；由具备相关方法学背景的专家核对内容、译文与评价难度，并依据配套评析形成候选缺陷清单，经拆分、去重和审查后确定各材料的预设有效缺陷总数。

材料准备分为文章适配和评分依据整理两部分。文章适配包括译文核对、术语统一、图表说明、段落编号及页面排版。评分依据整理从配套专家评析提取候选问题，再返回文章核查其事实基础和推断影响。对重复问题合并，对包含多个独立问题的表述拆分，并区分“明确成立的缺陷”和“信息不足或条件性建议”。

表 20 实验材料准备

材料准备项目	具体检查	形成的文件或记录
文章 A、B、C 选择	篇幅、方法知识、结构及评价难度	材料匹配说明
统一译文与图表	术语、数值、统计表述和上下文一致	参与者阅读版
原文定位	段落编号、表格标识与引用对应	两个 Agent 共享的材料版
候选缺陷整理	依据、成立理由、相互重复及独立性	每篇文章的候选缺陷表
专家审查	缺陷是否成立、边界是否清楚、难度是否适合	修订后的缺陷清单和评分依据
代表性答案	概括及解释不同分档的典型特征	评分训练材料

评分材料单独管理，并与参与者阅读版、Agent 材料版分开保存。各材料的有效缺陷总数在专家核对和试评后固定，前后测采用相同的判定与计分原则。

预实验前准备材料包、统一指导语、评分手册初稿、四位评分者试评方案、两个可运行 Agent、实验界面及数据记录方案。招募 4 名符合条件的学生试测正式流程，检查任务可理解性、文章难度、回答质量、疲劳与时限，特别关注论文 B 能否支持三组在训练阶段持续研读，以及无 AI 组是否过早结束任务。

同时检查 Agent 的原文理解、提示程度和对话重复，验证回答、日志、时间及评分能否完整记录。四位评分者使用各档代表性回答练习，讨论分歧并修订评分手册。预实验完成后固定正式材料、流程、时间、交互规则与评分标准，预实验参与者不进入正式样本。

预实验围绕流程可执行性与测量可用性展开。研究者记录参与者在哪个环节停顿、需要多少操作帮助、能否在时限内形成有依据的评价，以及训练中是否持续进行阅读、核对或讨论。测验后访谈参与者对任务理解与疲劳的感受，评分者则反馈标准是否足以处理实际回答。

表 21 预实验检查与调整

预实验重点	观察与检查	可能的调整
任务理解	能否区分概括与评价，是否知道需要结合原文说明理由	修改指导语和界面提示
材料难度	术语是否超出基础，回答是否过度集中于最低或最高水平	调整候选材料及译文
时间与疲劳	各阶段完成进度、休息需要及后半程状态	固定适合的时限和休息安排
三组训练活动	无 AI 组是否有可持续的研读任务，AI 是否帮助或打断讨论	调整任务说明、材料和交互
Agent 表现	原文理解、回复准确性、帮助程度和重复追问	修订提示和对话规则

评分可执行性	缺陷能否划分，分档是否清楚，评分耗时是否可行	补充示例并修订评分手册
数据完整性	文本、笔记、问卷、日志与阶段权限是否正确保存	修复记录与权限问题

预实验的 4 名参与者用于发现流程问题和调整材料，不用于估计稳定的训练效应。预实验修改完成后，保留版本记录，确定正式实验的材料、时间、评分手册及 Agent 配置。

2.4.3 自变量与控制变量

（1）自变量

本研究的自变量为 Agent 辅助方式，是一个包含三个水平的组间变量，分别为无 AI 独立阅读、通用 Agent 辅助阅读和苏格拉底式 Agent 辅助阅读。通过随机分组，使参与者在训练阶段接受其中一种支持方式。两个 AI 组使用相同的底层模型与信息条件，区别在于是否配置持续追问与自适应支架的教学互动策略。各水平的操作性定义如下。

表 22 三组训练条件

组别	训练阶段的支持	参与者开展的活动
无 AI 组	论文、统一译文、基础阅读、标注和笔记工具	独立阅读、回看、核对依据并记录判断与疑问
通用 Agent 组	相同基础工具，加通用 Agent	可请 AI 解释、总结、答疑和分析，并围绕论文讨论
苏格拉底式 Agent 组	相同基础工具与底层模型，加自适应追问规则	与 AI 讨论判断，通过追问和必要提示检查、完善理由

（2）控制变量

三组使用相同训练论文 B 和任务目标，时限、休息安排、电脑规格及基础阅读界面一致。两个 AI 组使用相同模型版本、生成参数、材料与方法学参考、检索工具及权限、上下文保留规则，不提供文章专属评析或评分答案。两组均可在整个训练阶段使用 Agent，采用同等便利的讨论入口。

操作培训时长一致。实验员仅处理操作问题，不提供论文内容或研究评价指导。前后测均独立完成，不使用 AI、外部搜索、训练笔记或聊天记录，不相互讨论，允许查看当前测验文章。四位评分者在不知道组别和训练日志的情况下独立评分。

表 23 实验控制安排

控制方面	具体安排
参与者资格与分组	采用统一的纳入标准，要求具备相关方法课程基础、科研实践经验有限且未接触实验材料；计划招募 100 人，符合条件者按 1：1：1 的比例随机分配，使三组人数尽量均衡；目标有效样本 90 人、每组 30 人；不设置性别配额。

材料与任务	三组使用相同的训练论文 B、统一译文及排版，接受相同的研读目标与笔记要求；前后测使用相同的任务指导语。训练不要求完成固定题单或提交完整报告。
材料顺序	在各组内平衡安排 A→C 与 C→A 两种前后测顺序，以每组 30 名有效样本为目标，两种顺序各 15 人；招募与分配时尽量保持均衡，并记录实际分布，避免材料顺序与组别混淆。
时间与施测环境	三组采用相同的前测、训练和后测时限及休息安排，训练后完成任务负荷测量并休息约 10 分钟，再进行后测，记录实际间隔；若实施备选延迟后测，统一延迟天数并记录实际间隔；使用相同规格的电脑、基础阅读界面、标注与笔记功能。具体时限经预实验确定后固定。
操作培训与实验员支持	三组操作说明时长一致，确保参与者会使用所属工具；两个 AI 组采用相同开场和同等便利的讨论入口。实验员仅处理操作问题，不提供论文内容或研究评价方面的指导。
两个 AI 组的技术与信息条件	使用相同模型版本、共同的生成参数设置、搜索工具与权限、上下文保留规则；提供相同的论文内容及通用方法学参考原则。研究者不向任何一组额外输入文章专属评析、缺陷清单或评分答案。主要操纵为教学互动策略。
测验期间的工具限制	前后测三组均独立完成，不使用 AI、外部搜索、训练阶段笔记或聊天记录，不相互讨论；允许查看当前测验文章。
评分程序	采用统一评分手册，由经过培训的评分者独立盲评，不向其提供参与者组别及训练日志；按预先规定的方式检验一致性并处理分歧。

控制分为实验程序控制与统计调整。课程基础、科研经历及材料接触情况通过纳入标准控制；材料、任务、时长、工具、实验员支持和评分程序在组间保持一致。对应前测得分及材料顺序纳入主要统计模型。初始批判性思维倾向作为探索性调节变量，任务负荷和互动记录用于补充评价与过程分析。

2.4.4 实验流程

提前安排约 35 分钟完成知情同意、资格与背景登记及批判性思维倾向测量，其中 CCTDI 暂按 30 分钟安排。正式训练当天约 171 分钟，流程见下表。全部时限经预实验检验后固定。

表 24 训练当天流程

阶段	暂定时长	主要内容
说明与界面熟悉	5 分钟	用不涉及正式材料的示例介绍操作
前测	40 分钟	独立阅读 A 或 C，完成研究概括与研究评价
休息	10 分钟	暂停任务，不讨论文章
分组工具说明	5 分钟	熟悉所属阅读工具与 Agent 入口
训练	50 分钟	三组研读论文 B，按共同任务要求记录判断、依据或疑问
主观任务负荷	4 分钟	完成 NASA-TLX 六个维度评分
训练后休息	10 分钟	暂停任务，不查看 AI、笔记或评析
后测规则提醒	2 分钟	确认独立完成的要求

后测	40 分钟	独立阅读另一篇 C 或 A，完成相同类型任务
收尾	5 分钟	确认完成情况并结束实验

前后测均包含两个任务。研究概括指导语为：“请简要概括本文的研究问题、研究方法、主要结果，以及作者据此得出的结论。”研究评价指导语为：“请评价这项研究及其结论是否得到充分支持。指出你认为存在的缺陷，并结合文中的具体信息解释理由。”每次测验暂定阅读 15 分钟、概括 8 分钟、识别缺陷 6 分钟、解释理由 8 分钟、检查提交 3 分钟，作答时可回看文章。

训练阶段三组使用相同任务指导语：“请研读论文 B，理解其研究问题、方法、结果与结论，并判断研究方法和结果是否充分支持结论。阅读时，请用简短笔记或批注记录你的判断、依据或疑问，不限数量，无需提交完整报告。”随后分别说明独立阅读、通用 AI 帮助或追问式帮助的使用方式。该阶段保留自主研读与讨论空间，不要求完成固定题单。

表 25 前后测内部流程

测验内环节	参考时长	任务与可使用的信息
浏览文章	3 分钟	查看标题、摘要、章节与图表，了解结构
通读文章	7 分钟	阅读研究问题、方法、结果和讨论，可标记与记笔记
重点回看	5 分钟	回看不清楚的研究步骤、数据和结论
研究概括	8 分钟	说明研究问题、方法、结果和作者结论
识别研究缺陷	6 分钟	找出认为成立的问题，定位依据
解释批评理由	8 分钟	结合具体信息说明问题为什么影响研究判断
检查与提交	3 分钟	检查、去重、修订并提交两项回答
合计	40 分钟	作答期间可回看当前文章

训练当天的前测后不提供分数和参考答案，参与者休息后进入论文 B 的训练。分组补充说明分别为：“请使用阅读、标注和笔记工具独立完成”；“你可以使用 AI 助手进行解释、答疑和讨论”；“你可以与 AI 助手讨论，它会通过追问和必要提示，帮助你检查并完善自己的判断”。共同研读目标和记录要求保持一致。

无 AI 组在 50 分钟内独立阅读、回看方法与结果、核对结论并记录判断或疑问。两个 AI 组在相同时间内可自由使用所属 Agent，不设置前若干分钟禁止 AI 的单独阶段。三组均可自主调整阅读顺序，不限定批注或笔记数量，也不要求提交完整训练报告。平台保存这些过程资料，研究者记录实际阅读、讨论及技术问题。

训练结束后完成 NASA-TLX 并休息，再开启独立后测。后测使用另一篇 A 或 C，任务和权限与前测相同，训练阶段的聊天记录和笔记不再开放。实验员提醒独立完成规则并处理操作问题。整个核心安排包含提前测量约 35 分钟及训练当天约 171 分钟，共约 206 分钟。

当前主要后测在训练后休息约 10 分钟进行。延迟后测作为备选安排：若实施，将在正式实

验前确定固定间隔，另选同类模拟研究文章 D，采用相同任务和评分规则，并统一记录实际间隔。延迟后测另行安排补偿与分析，不纳入本报告当前的主要检验。

2.4.5 因变量及其测量

本研究的因变量包括论文内容概括表现和批判性评价表现，均通过前后测的独立书面作答测量。论文内容概括表现是次要因变量，指参与者能否准确把握论文的研究问题、研究方法、主要结果和作者结论。批判性评价表现是主要因变量，指参与者能否识别研究中的有效缺陷，并结合具体依据作出推理成立的解释；其中，缺陷识别击中率和平均解释质量为主要测量指标，缺陷识别精确率为补充指标。

（1）批判性评价表现

缺陷识别击中率反映参与者能够发现多少预设有效缺陷，平均解释质量反映其对有效缺陷的解释是否充分。评分首先把参与者提出的批评分解为不同缺陷，同一问题的重复表达合并。结合原文及评分手册判断每项是否具体且成立，得到有效缺陷数。缺陷识别击中率 = 有效缺陷数 / 该材料预设有效缺陷总数。

对回答先进行缺陷单元划分，再判断是否有效。同一段文字涉及两个相互独立的问题时分别记录；多处文字表达同一问题时合并；只陈述优点或描述论文内容的句子不计为所提缺陷。有效缺陷须指向具体研究做法或推断，并具有成立的事实或方法依据。每篇材料在评分手册中给出典型表达与边界案例，便于四位评分者按相同单位工作。

表 26 因变量的操作性定义与计分

因变量及测量指标	操作性定义	计分方式	指标用途
批判性评价表现：缺陷识别击中率	发现预设有效研究缺陷的比例	有效缺陷数÷该材料预设有效缺陷总数	主要因变量的主要指标
批判性评价表现：平均解释质量	对有效缺陷说明依据与推理的充分程度	各有效缺陷解释分之和÷有效缺陷数，零有效缺陷记 0	主要因变量的主要指标
批判性评价表现：缺陷识别精确率	所提出不同缺陷中成立的比例	有效缺陷数÷提出的不同缺陷总数	主要因变量的补充指标
论文内容概括表现	对研究问题、方法、结果和结论的准确把握	依据整体标准评 0—3 分	次要因变量

对每项有效缺陷的解释按 0—3 分评价：

表 27 单个有效缺陷的解释质量评分标准

得分	解释质量标准
0 分 未形成有效解释	只贴标签或笼统断言；或存在关键事实误解、不适用的方法原则、根本性推理错误，无法说明问题为什么成立
1 分 部分解释	有相关理由和可成立成分，但依据不够具体或推理联系较弱，存在明显缺口
2 分 基本充分解释	使用基本准确、相关的信息，主要推理成立，但关键依据或某一联系未充分展开，需要少量补充
3 分 充分解释	将研究具体做法、适用的方法或推断原则及其后果连接成连贯推理，依据明确，无影响批评成立的关键缺口

平均解释质量 = 各有效缺陷解释质量得分之和 / 有效缺陷数。有效缺陷没有解释时，该项记 0 分并计入分母；未识别任何有效缺陷时，平均解释质量按特殊规则记 0 分。重复缺陷合并相关文字后评分。清单外的合理缺陷单独记录，经专家核定需要补入清单时，对所有回答按统一标准重新评分。

缺陷识别精确率为补充指标，计算为有效缺陷数 / 提出的不同缺陷总数。提出了缺陷但均不成立时，精确率为 0；未提出任何缺陷时分母为 0，精确率无定义，单独记录并报告人数。该指标用于结合击中率判断参与者是否通过大量提出不成立的批评获得较高发现数量。

评分时以文字体现的依据和推理为准。例如，对于“自愿参加培训造成组间可比性问题”这一有效缺陷，只写“没有随机分组”可以识别问题，但尚未形成解释；写出“参加者可能原本更积极”形成了部分联系；进一步说明这种差异也可能影响结果，使培训与成绩差异之间存在替代解释，则体现更充分的推理。示例将在专家核对后写入手册，并与正式材料的具体信息对应。

（2）论文内容概括表现

论文内容概括表现为次要因变量。借鉴 CriTrainer 的概括评价思路（Yuan et al., 2023），按 0—3 分评分：0 分为内容基本无关或错误，无法识别研究主线；1 分为只准确呈现部分内容，关键遗漏或误解使主线不清；2 分为主线基本准确，存在不影响主要理解的局部遗漏或不精确；3 分为准确呈现研究问题、方法、主要结果和结论及其关系，无实质性误解。

四项指标共同呈现阅读表现。击中率描述发现范围，解释质量描述理由是否充分，精确率补充考察批评中成立的比例，概括则帮助了解学生是否准确理解研究主线。保留每位参与者的有效缺陷数和所提缺陷总数，以便解释比例指标背后的实际数量。

2.4.6 探索性调节变量与过程测量

（1）探索性调节变量

本研究的探索性调节变量为初始批判性思维倾向，指参与者在训练前愿意运用批判性思维审查信息、证据和判断的倾向。研究探索苏格拉底式 Agent 相对通用 Agent 的训练效果是否随初始倾向而变化。

使用正式授权版本的 CCTDI 测量初始批判性思维倾向，按手册施测和计分，暂按 75 题安

排。主要使用总分作为连续变量，七个维度用于描述（Insight Assessment, n.d.）。同时记录年级、已修课程、科研辅助经历、论文阅读及 AI 使用经历。

（2）任务负荷与过程测量

训练后使用 NASA-TLX 评价主观任务负荷，覆盖心理需求、身体需求、时间需求、表现、努力和挫折六个方面（Hart & Staveland, 1988）。本研究采用六维评分的非加权均值，统一各维度方向后汇总，并分别报告维度结果。

保存阅读时间、笔记、批注及两个 AI 组的对话日志。对话分析关注学生是否补充推理前提、解释研究做法与结论的关系、提出有依据的替代解释，或在发现矛盾后修正判断并说明理由。编码区分自主生成、提示后生成和复述 AI 内容，同时记录 Agent 的追问类型、帮助程度、直接解释及重复情况。过程数据用于描述互动策略和自我解释的发生情况。

表 28 训练过程记录与分析用途

过程记录	观察内容	分析用途
自主生成解释	在 AI 给出对应推理前，学生主动连接依据、原则与结论	描述学生自主开展的推理
提示后生成解释	经开放问题、方向或具体线索后，学生补出关键联系	描述追问之后的学习活动
复述 AI 内容	重复已给出的理由，未增加可辨认的推理联系	与学生生成的解释区分
判断修正	明确改变原有判断，并说明修改理由	描述理解修正过程
Agent 教学动作	追问依据、理由、替代解释、限定或提供讲解	检查两类 Agent 的互动差异
帮助程度与推进	提供哪些线索，之后是否出现新的解释	结合片段理解支持适切性

对话编码以能够识别的推理片段为单位，结合前后文判断解释来源。研究者制定编码说明，抽取样本由另一名编码者独立核对，处理分歧后汇总各类片段及典型过程。对话用于说明学生如何参与训练，以及系统是否执行了预定策略；本研究不把自我解释设置为正式中介检验。

2.4.7 评分质量控制

评分手册依据文章配套评析、方法学原则与专家审查建立。对每项预设缺陷记录问题名称、原文位置、成立理由、相近但不成立的批评以及典型解释；概括部分记录各文章应包含的核心内容及关键误解。专家检查内容覆盖和判断依据，预实验回答用于补充实际表达和分档样例。

四位评分者先用共同练习材料培训，独立试评后比较分歧，重点统一缺陷单元划分、重复合并、有效性和解释分档。正式回答匿名化并打乱顺序，评分者不获得组别和训练日志。原始评分用于估计一致性，随后按预定程序处理分歧，保留复核记录。

表 29 四位评分者的评分流程

评分阶段	具体操作	形成的数据
划分与对应	将回答划分为不同缺陷，与材料清单对应，标出清单外问题	缺陷单元、原文及清单编号
有效性独立判定	四人根据手册判断问题是否具体且成立	每位评分者的 0 / 1 判定
一致性检查与复核	汇总独立判定，复核争议事实及方法问题	原始一致性指标与最终有效缺陷集合
质量独立评分	对统一后的有效缺陷逐项评解释分，并评价概括	四位评分者的 0—3 分原始记录
汇总参与者得分	对质量评分取四人均值，再计算参与者指标	前后测击中率、精确率、解释和概括得分

有效性判定在统一的“回答—缺陷单元”上计算多评分者一致性，拟采用 Fleiss κ，并报告一致比例。概括和解释的评分报告绝对一致性、平均测量的 ICC 及置信区间，模型中说明四位评分者与全部回答的交叉安排。质量分数使用四人平均值，因此一致性评价同时关注最终平均评分的可靠性。计算均基于协调分歧之前保留的独立评分。

对于发现较集中的评分分歧，返回材料和规则检查原因；事实或方法学判断存在争议时由专家复核，规则调整适用于全部同类回答。评分质量报告包括专家核对过程、试评修改、正式一致性及分歧处理方式，形成从材料依据到实际计分的完整记录。

2.4.8 数据整理与统计分析

正式分析前整理参与者层面的数据表，同时保留缺陷层面的原始判定与解释评分。参与者表包括匿名编号、组别、材料顺序、初始倾向、各指标前后测得分、有效与所提缺陷数、任务负荷、完成情况及实际后测间隔。

描述统计按组报告招募、分配、完成和纳入人数，展示主要指标的均值、标准差及分布。偏斜明显时补充中位数和四分位距；同时列出零有效缺陷和未提出缺陷者的人数，精确率注明实际可计算的样本量。

主要效果分别建立两个协方差分析模型，以后测缺陷识别击中率、后测平均解释质量为因变量，组别为组间因素，调整对应前测得分和材料顺序。前测调整有助于在比较干预条件时利用初始表现信息（Vickers & Altman, 2001）。从每个模型提取“苏格拉底式 Agent 对通用 Agent”和“苏格拉底式 Agent 对无 AI”两项预设比较，共四项主要比较，统一采用 Holm 法校正（Holm, 1979）。

主要分析写为以下两个模型，其中组别以虚拟变量表示，材料顺序编码为 A→C 或 C→A：

模型一：后测缺陷识别击中率 = 截距 + 组别 + 前测缺陷识别击中率 + 材料顺序 + 误差。

模型二：后测平均解释质量 = 截距 + 组别 + 前测平均解释质量 + 材料顺序 + 误差。

表 30 主要假设与预设比较

假设	结果模型	事先计划的比较
H1a	批判性评价表现：缺陷识别击中率	苏格拉底式 Agent 组- 通用 Agent 组
H1b	批判性评价表现：缺陷识别击中率	苏格拉底式 Agent 组- 无 AI 组
H1c	平均解释质量	苏格拉底式 Agent 组- 通用 Agent 组
H1d	平均解释质量	苏格拉底式 Agent 组- 无 AI 组

四项比较采用双侧检验，统一进行 Holm 校正。报告各组调整均值、调整后均值差、效应量、95%置信区间及原始和校正后 p 值。假设支持情况结合估计方向与校正结果判断；常规 95%区间标明未经多重比较调整。

精确率作为补充分析，调整对应前测和材料顺序，提取苏格拉底式 Agent 与另外两组的两项比较，单独进行 Holm 校正。前后测均有定义的参与者进入该调整模型，同时报告各组零分母人数及所涉样本范围。概括表现作为次要结果，采用对应前测调整的协方差分析，先报告整体组别效应；进一步两两比较时单独进行 Holm 校正。

线性模型采用 HC3 稳健标准误，报告调整后的均值差、95%置信区间、效应量和校正后的 p 值。检查得分分布、模型残差与回归斜率关系，并对比例或低分聚集明显的结果进行敏感性分析。置信区间与多重检验校正的范围分别说明。

精确率是 0—1 比例，各人的所提缺陷总数不同。正式模型将在预实验后固定：若采用线性协方差分析，使用稳健标准误并检查分布；若小分母或边界聚集明显，则采用能够利用有效与无效缺陷计数的比例模型，并检查过度离散。前测或后测未提出任何缺陷时单独标记，报告进入精确率分析的样本范围。概括分数仅有 0—3 档，必要时以有序模型检查结论对分析方式的敏感性。

探索性调节分析以通用 Agent 组为参照，将标准化 CCTDI 总分、组别及二者交互项加入上述模型，重点检验苏格拉底式 Agent 相对通用 Agent 的效果是否随初始倾向变化。两个主要结果上的目标交互检验单独进行 Holm 校正，并在有解释价值时呈现不同倾向水平下的估计组间差异。

调节模型为：后测表现 = 截距 + 对应前测 + 材料顺序 + 组别 + 初始 CT 倾向 + 组别×初始 CT 倾向 + 误差。CT 倾向使用标准化连续总分，不进行高低组二分。三组编码产生两个组别项及相应交互项，重点解释苏格拉底组相对通用组的交互系数。

若目标交互系数为负，表示初始倾向较低时苏格拉底组的相对优势更大，方向符合补偿性预期。展示时在实际数据范围内呈现不同倾向水平的预测表现和组间差异，并依据交互项判断调节证据。两个主要结果上的目标交互分别估计后，统一进行探索性检验的 Holm 校正。

任务负荷报告描述统计与探索性组间比较；对话日志依据编码规则，由独立编码者核对代表性片段，汇总生成解释、提示后推进及判断修正等情况。过程分析不设正式中介模型。无 AI 组的笔记用于描述研读过程，不把不同记录渠道中的发言数量直接作为同一心理加工量进行比较。

记录各阶段完成情况及缺失原因。未完成测验与零分回答分开处理；零有效缺陷者按既定规则计分并保留。数据整理和分析前固定评分规则、主要比较及排除标准，报告实际纳入人数与任何方案调整。

结果解释分别对应两个主要指标及各比较对象。击中率较高说明发现了更多预设有效问题，解释质量较高说明所识别有效缺陷的理由更充分；再结合精确率判断提出批评的可靠程度。概括和任务负荷提供补充信息，帮助理解内容掌握和使用感受与评价表现之间的关系。

2.5 安全论证与可行性分析

2.5.1 研究伦理与数据管理

本研究以成年学生的论文阅读、讨论和书面评价为主要任务。正式招募前提交伦理审查，向参与者说明任务、时长、录音录屏与对话记录范围、自愿参加及退出权利。实验安排休息，允许因不适暂停或退出，补偿与表现高低无关。访谈中只收集参与者愿意展示的记录，避免收集未公开研究或第三方个人信息。

采用编号保存数据，身份与联系信息单独存放，限制研究团队访问权限；发送给模型的内容以实验材料及匿名化讨论为主。参与者回答不用于课程成绩评价。工具与评分材料分开管理，研究完成后按约定提供说明和反馈。

参与者在知情同意时了解两次参与的时间和报酬安排，正式实验按 150 元 / 人预算。遇到技术故障、身体不适或需要退出时，实验员记录实际完成情况并按事先说明处理补偿。模型服务不接收姓名、联系方式等身份字段，录音、录屏及日志以编号管理。

2.5.2 实施条件与阶段安排

本研究已有理论文献、同类系统研究和模拟论文材料基础，开发范围集中于阅读界面、原文定位及对话策略，便于分阶段实现。研究一、二的小规模访谈与测试用于及时修订需求和系统；预实验用于固定实验时长及评分规则。正式研究前完成 CCTDI 授权、材料使用安排、专家核对及评分者培训。按 100 名正式参与者、每人 150 元补偿估算，总预算约 26,400 元，包含访谈、可用性测试、预实验、评分、专家与模型费用及机动经费。

研究实施按阶段推进。研究一先形成具体设计要求，研究二以小规模测试检查界面与交互，研究三在预实验完成后开展正式招募。这样可以在大规模数据收集前发现材料难度、支持策略或评分上的问题，并把相应调整纳入固定版本。

研究工作量主要集中于 Agent 开发、正式实验组织和开放回答评分。开发优先完成全文阅读、引用定位、对话策略及日志功能；实验按照场次预约、统一设备和指导语实施；评分按匿名批次安排，并留出培训和复核时间。经费以计划招募 100 人编列，评分量按前后测全部回答和四位评分者估算，具体见进展与成果部分的经费表。

3．本研究的特色与创新之处

本研究将科研新手的论文评价困难落实到“识别有效缺陷”和“解释缺陷为什么成立”两类表现，并将原文证据与方法学推理结合起来设计支持。相较于提供概括、章节问题或直接分析，拟开发的 Agent 围绕学生当前判断选择追问内容，促使学生主动说明理由，再根据具体困难调整提示或讲解。

设计中把生成性学习与自我解释、最近发展区和 Toulmin 模型分别落实到学习活动、帮助程度和论证内容，形成可记录、可检查的交互规则。通过真实阅读经历访谈、可用性测试与三组实验，将设计依据、使用体验和独立表现衔接起来。

实验在相同模型与信息条件下比较通用和苏格拉底式 Agent，并设置无 AI 参照，使用独立前后测评价学习效果。结果同时关注有效缺陷的发现比例、解释质量和批评精确率，形成适用于本研究材料的评分手册，为后续科研阅读工具的设计与评价提供参考。

4．预期的论文进展和成果

4.1 进度安排

表 31 论文进度安排

时间	主要工作	阶段产出
2026 年 10—11 月	完成开题、补充文献与同类工具比较，开展研究一访谈	开题报告、设计依据与需求分析
2026 年 12 月—2027 年 1 月	开发阅读系统与 Agent，完成两轮可用性测试	可运行原型、交互规则与迭代记录
2027 年 2 月	完成材料核对、评分者培训及预实验	正式材料包、流程、评分手册
2027 年 3 月	招募并实施正式实验，同步整理数据与盲评	实验数据、原始评分与过程记录
2027 年 4 月	完成统计分析、过程分析与论文初稿	分析结果、研究报告和论文初稿
2027 年 5—6 月	修改论文、完善系统说明并准备答辩	学位论文、系统与答辩材料

以上为拟定安排，具体节点与培养单位后续通知衔接。

4.2 预期成果

预期形成以下相互对应的研究成果：

表 32 预期研究成果

成果	主要内容	对应研究
设计依据与需求分析	理论及同类工具比较、真实阅读困难、设计要求及依据	研究一

可运行的文献阅读 Agent	原文定位、追问策略、自适应帮助、跨轮记录及共同阅读界面	研究二
可用性与迭代记录	两轮问题、用户反馈、SUS 结果及修改前后证据	研究二
实验材料与评分手册	文章版本、统一指导语、缺陷依据、解释与概括评分规则	研究三
效果与过程分析	三组独立表现、探索性倾向调节及对话过程描述	研究三
学位论文与设计建议	贯通设计依据、产品实现、可用性和学习效果的研究报告	全部研究

研究结果将说明苏格拉底式支持在本研究条件下能否改善独立文献评价，以及这种效果体现在哪些表现上。最终完成应用心理专业学位论文，并整理可复核的材料与分析记录。

4.3 经费安排

表 33 研究经费预算

项目	估算依据	金额（元）
研究一访谈	8 人×30 元	240
可用性测试	12 人×50 元	600
预实验	4 人×150 元	600
正式实验	100 人×150 元	15,000
评分劳务	100 人×2 次×4 人×15 分钟，30 元 / 小时	6,000
评分者培训	4 人×3 小时×30 元	360
专家咨询	暂估	500
模型与运行	暂估	500
材料与杂费	暂估	200
小计		24,000
机动经费	小计的 10%	2,400
合计		26,400

预算对应当前主要研究安排，参与者补偿和评分劳务均按计划招募 100 人预留。量表授权如产生额外费用，及备选延迟后测的补偿，将在实施前另行核定。

三、论文大纲（可加页）

第一章 绪论

1.1 研究背景与问题提出

1.2 研究意义

1.3 研究目标、内容与总体路线

第二章 文献综述与理论基础

2.1 科研新手的论文阅读与文献批判性评价
2.2 文献批判性评价的任务与测量
2.3 AI 辅助学习及独立学习结果
2.4 AI 论文阅读工具与苏格拉底式 Agent 研究
2.5 生成性学习与自我解释
2.6 最近发展区、自适应支架与 Toulmin 论证模型
2.7 研究述评与研究问题

第三章 研究一 设计依据与需求分析

3.1 研究目的与方法
3.2 文献及同类工具比较
3.3 参与者、访谈流程与分析方法
3.4 科研新手的阅读困难与支持需要
3.5 Agent 设计要求及其依据

第四章 研究二 Agent 开发与可用性测试

4.1 产品定位与整体架构
4.2 阅读界面、信息输入与原文定位
4.3 论证分析与追问策略
4.4 自适应帮助和跨轮讨论
4.5 系统实现与开发检查
4.6 两轮可用性测试的方法、结果与迭代
4.7 正式实验版本

第五章 研究三 效果实验

5.1 研究问题与假设
5.2 实验设计、参与者与样本量
5.3 材料准备与预实验
5.4 实验条件、变量测量与评分质量
5.5 实验流程与数据分析
5.6 缺陷识别、解释质量及概括结果
5.7 探索性调节与训练过程分析

第六章 综合讨论

6.1 不同辅助方式与独立文献评价表现
6.2 追问、自适应支持与自我解释过程
6.3 科研新手阅读 Agent 的设计建议
6.4 研究局限与后续研究

第七章 结论

参考文献

附录：访谈提纲、可用性测试材料、实验指导语、评分手册及 Agent 交互规则

四、主要参考文献

Archila, P. A., Ortiz, B. T., & Truscott de Mejía, A.-M. (2025). Beyond the passive absorption of information: Engaging students in the critical reading of scientific articles. *Science & Education, 34*, 2189–2223. https://doi.org/10.1007/s11191-024-00507-1

Arriagada Anabalón, S., Nussbaum Voehl, M., Navarro, N., & Araya, J. (2026). Technology-mediated scaffolding to support critical thinking in pre-service teachers' academic writing. *Education Sciences, 16*(10), Article 1658. https://doi.org/10.3390/educsci16101658

Bastani, H., Bastani, O., Sungu, A., Ge, H., Kabakcı, Ö., & Mariman, R. (2025). Generative AI without guardrails can harm learning: Evidence from high school mathematics. *Proceedings of the National Academy of Sciences, 122*(26), Article e2422633122. https://doi.org/10.1073/pnas.2422633122

Bjorn, G. (2024). The CERIC method plus social collaborative annotation improves critical reading of the primary literature in an interdisciplinary graduate course. *Frontiers in Education, 9*, Article 1257747. https://doi.org/10.3389/feduc.2024.1257747

Brooke, J. (1996). SUS: A "quick and dirty" usability scale. In P. W. Jordan, B. Thomas, B. A. Weerdmeester, & I. L. McClelland (Eds.), *Usability evaluation in industry* (pp. 189–194). Taylor & Francis. https://hci-studies.org/methods-and-measures/downloads/SUS_Brooke1996.pdf

Cai, Y. W., & Chen, Z. (2025). The double-edged sword: The impact of generative artificial intelligence use on college students' critical thinking. *Journal of Central China Normal University (Humanities and Social Sciences), 64*(6), 146–159. https://journal.ccnu.edu.cn/sk/CN/abstract/abstract6513.shtml
[蔡颖蔚, 陈茁. (2025). 双刃之剑：生成式人工智能对大学生批判性思维的影响. 华中师范大学学报（人文社会科学版）, *64*(6), 146–159.]

Chi, M. T. H. (2000). Self-explaining expository texts: The dual processes of generating inferences and repairing mental models. In R. Glaser (Ed.), *Advances in instructional psychology* (pp. 161–238). Lawrence Erlbaum Associates. https://education.asu.edu/lcl/publications/chi-m-t-h-2000-self-explaining-expository-texts-dual-processes-generating-0

Chi, M. T. H., de Leeuw, N., Chiu, M.-H., & LaVancher, C. (1994). Eliciting self-explanations improves understanding. *Cognitive Science, 18*(3), 439–477. https://doi.org/10.1207/s15516709cog1803_3

Facione, P. A. (1990). *Critical thinking: A statement of expert consensus for purposes of educational assessment and instruction. Research findings and recommendations* (ED315423). American Philosophical Association. https://eric.ed.gov/?id=ED315423

Fan, Y., Tang, L., Le, H., Shen, K., Tan, S., Zhao, Y., Shen, Y., Li, X., & Gašević, D. (2025). Beware of metacognitive laziness: Effects of generative artificial intelligence on learning motivation, processes, and performance. *British Journal of Educational Technology, 56*(2), 489–530. https://doi.org/10.1111/bjet.13544

Fang, X., Xu, A., Yang, C.-L., Lin, Y.-F., Malacria, S., & Yatani, K. (2026). LLM-based in-situ thought exchanges for critical paper reading. In *Proceedings of the 31st International Conference on Intelligent User Interfaces*. Association for Computing Machinery. https://doi.org/10.1145/3742413.3789069

Faul, F., Erdfelder, E., Buchner, A., & Lang, A.-G. (2009). Statistical power analyses using G*Power 3.1: Tests for correlation and regression analyses. *Behavior Research Methods, 41*(4), 1149–1160. https://doi.org/10.3758/BRM.41.4.1149

Fiorella, L., & Mayer, R. E. (2016). Eight ways to promote generative learning. *Educational Psychology Review, 28*(4), 717–741. https://doi.org/10.1007/s10648-015-9348-9

Hart, S. G., & Staveland, L. E. (1988). Development of NASA-TLX (Task Load Index): Results of empirical and theoretical research. In P. A. Hancock & N. Meshkati (Eds.), *Human mental workload* (pp. 139–183). North-Holland. https://doi.org/10.1016/S0166-4115(08)62386-9

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics, 6*(2), 65–70. https://www.jstor.org/stable/4615733

Hu, J. Y., Yan, T. M., & Zhang, T. T. (2026). Breaking through cognitive outsourcing: Designing a human-machine collaborative argumentation system for critical thinking. *e-Education Research, 47*(3), 54–63. https://doi.org/10.13811/j.cnki.eer.2026.03.007
[胡金艳, 闫恬萌, 张彤彤. (2026). 突破认知外包：面向批判性思维的人机协作辩论系统设计. 电化教育研究, *47*(3), 54–63.]

Hugenroth, P., Danry, V., & Maes, P. (2026). *Critical Inker: Scaffolding critical thinking in AI-assisted writing through Socratic questioning* [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2604.07167

Insight Assessment. (n.d.). *California Critical Thinking Disposition Inventory.* Retrieved October 26, 2026, from https://insightassessment.com/iaproduct/california-critical-thinking-disposition-inventory/

Lee, S., Zhong, M., Foster, C., Segura-Totten, M., & McCartney, M. (2022). From novice to expert: An assessment to measure strategies students implement while learning to read primary scientific literature. *Journal of Microbiology & Biology Education, 23*(3), Article e00126-22. https://doi.org/10.1128/jmbe.00126-22

Li, H. F., Wang, W., Li, G. X., & Wang, Y. (2024). Teaching method of intelligent midwifery: Taking the teaching practice of Socratic chatbot as an example. *Open Education Research, 30*(2), 89–99. https://doi.org/10.13966/j.cnki.kfjyyj.2024.02.010
[李海峰, 王炜, 李广鑫, 王媛. (2024). 智能助产术教学法——以“智能苏格拉底会话机器人”教学实践为例. 开放教育研究, *30*(2), 89–99.]

Meltzoff, J., & Cooper, H. (2018). *Critical thinking about research: Psychology and related fields* (2nd ed.). American Psychological Association. https://doi.org/10.1037/0000052-000

Namaziandost, E., & Teng, M. F. (2026). AI-supported Socratic dialogue agents vs. generic AI chatbots for intermediate EFL learners' critical thinking, epistemic beliefs, and argumentation: Mixed-methods evidence. *International Journal of Applied Linguistics*. Advance online publication. https://doi.org/10.1111/ijal.70268

Qi, J., Xu, Y. R., Liu, J. A., & Xue, K. (2024). The impact of generative artificial intelligence tools on college students' critical thinking and autonomous learning ability. *e-Education Research, 45*(12), 67–74. https://doi.org/10.13811/j.cnki.eer.2024.12.009
[戚佳, 徐艳茹, 刘继安, 薛凯. (2024). 生成式人工智能工具使用对高校学生批判性思维与自主学习能力的影响. 电化教育研究, *45*(12), 67–74.]

Shi, M., Wang, J., Ni, J., Pal Chowdhury, S., & Sachan, M. (2026). Tackling the root of misinformation by teaching laypeople about logical fallacies via Socratic questioning and critical argumentation. In *Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 47821–47868). Association for Computational Linguistics. https://doi.org/10.18653/v1/2026.acl-long.2209

Stadler, M., Bannert, M., & Sailer, M. (2024). Cognitive ease at a cost: LLMs reduce mental effort but compromise depth in student scientific inquiry. *Computers in Human Behavior, 160*, Article 108386. https://doi.org/10.1016/j.chb.2024.108386

Sternberg, R. J., & Sternberg, K. (2017). Measuring scientific reasoning for graduate admissions in psychology and related disciplines. *Journal of Intelligence, 5*(3), Article 29. https://doi.org/10.3390/jintelligence5030029

Timmerman, B. E. C., Strickland, D. C., Johnson, R. L., & Payne, J. R. (2011). Development of a 'universal' rubric for assessing undergraduates' scientific reasoning skills using scientific writing. *Assessment & Evaluation in Higher Education, 36*(5), 509–547. https://doi.org/10.1080/02602930903540991

Toulmin, S. E. (2003). *The uses of argument* (Updated ed.). Cambridge University Press. https://doi.org/10.1017/CBO9780511840005

Vickers, A. J., & Altman, D. G. (2001). Analysing controlled trials with baseline and follow up measurements. *BMJ, 323*(7321), 1123–1124. https://doi.org/10.1136/bmj.323.7321.1123

Vygotsky, L. S. (1978). *Mind in society: The development of higher psychological processes* (M. Cole, V. John-Steiner, S. Scribner, & E. Souberman, Eds.). Harvard University Press. https://www.hup.harvard.edu/books/9780674576292

Wittrock, M. C. (2010). Learning as a generative process. *Educational Psychologist, 45*(1), 40–45. https://doi.org/10.1080/00461520903433554 (Original work published 1974)

Xi, L., Zhang, Y., & Wang, Q. (2026). Investigating the effects of an LLM-based Socratic conversational agent on students' academic performance and reflective thinking in higher education. *Computers & Education, 241*, Article 105494. https://doi.org/10.1016/j.compedu.2025.105494

Yuan, K., Lin, H., Cao, S., Peng, Z., Guo, Q., & Ma, X. (2023). CriTrainer: An adaptive training tool for critical paper reading. In *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology* (pp. 1–17). Association for Computing Machinery. https://doi.org/10.1145/3586183.3606816

Yurt, E. (2026). The effects of AI-assisted flipped learning on critical thinking skills, dispositions, and motivation in higher education. *Discover Artificial Intelligence, 6*, Article 1510. https://doi.org/10.1007/s44163-026-01773-4

赵晓伟, 王师晓, 李情, 沈书生, 祝智庭. (2025). 苏格拉底式问题支架：促进学生向 AI 大模型提出高质量问题. 现代远程教育研究, *37*(1), 102–112. https://doi.org/10.3969/j.issn.1009-5195.2025.01.011

五、导师意见

导师签名：_____

年　　月　　日